

기차역 공간의 혼잡도 예측을 위한 AI 기반 접근

-AI 적용 군중 예측의 건축적 가능성-

An AI-Based Approach to Predicting Crowd Congestion in Railway Station Environments

- Architectural Potential of AI-Based Crowd Prediction -

정 미 주*

Jeong, Mi-Joo

* 성균관대 건축학과 학사과정, Dept. of Architecture, Sungkyunkwan University, Korea

지도교수: 김우영

심사위원: 신중진, 이한중, 전이서, 정관택, 황정현

초 록

본 연구는 복잡한 시공간 구조를 지닌 기차역 공간에서 발생하는 군중 혼잡 문제를 해결하기 위해, 인공지능(AI)에 기반한 예측 기법의 적용 가능성을 고찰한다. 기존의 혼잡 관리 방식이 사후 모니터링과 단순 지표에 의존함에 따라 실제 공간의 비선형적·연쇄적 혼잡 패턴을 반영하지 못한다는 한계를 바탕으로, 본 연구는 머신러닝(XGBoost, LightGBM, SVR)과 딥러닝(GNN, CNN, Transformer 등)의 혼잡 예측 성능과 데이터 요구 특성을 비교·분석하였다. 또한 홍콩 MTR 카이탁역의 실시간 운영형 예측 시스템과 일본 도쿄 돔 주변의 계획·설계 지원형 시뮬레이션 사례를 조사하여, AI 기술이 건축공간의 동선 구조 해석 및 운영 전략 수립에 기여하는 방식을 검토하였다. 연구 결과, AI 기반 예측 기술은 기차역의 복합적 동선 체계와 외부 변수를 통합적으로 해석하여 사전 대응 능력을 향상시키며, 설계·운영 단계 모두에서 공간 의사결정 도구로 활용될 수 있음을 확인하였다. 본 연구는 향후 실제 역사 데이터를 활용한 시뮬레이션과 데이터 기반 설계 프레임워크 구축의 필요성을 제안한다.

키워드 : 인공지능(AI), 군중 혼잡 예측, 기차역 건축공간, 시공간 모델링, 그래프 신경망(GNN), 트랜스포머, 스마트 모빌리티

Keywords : Artificial Intelligence (AI), Crowd Congestion Prediction, Train Station Architecture, Spatio-Temporal Modeling, Graph Neural Network (GNN), Transformer, Smart Mobility

1. 서론: 배경 및 목적

1.1 문제 제기: 기존 예측 방법의 한계

지하철 앱을 확인하면 “혼잡함”이라고 표시되지만, 실제로 역에 도착하면 생각보다 한산하거나 그 반대의 경우가 빈번하다. 또는 “5분 후 도착”이라고 했지만 실제로는 10분이 넘게 기다려야 하는 경험은 누구나 있을 것이다. 이러한 부정확성은 현재 기차역 공간의 혼잡도 예측 시스템이 근본적인 한계를 가지고 있음을 보여준다.

1.1.1 사후 모니터링만 가능

현재 대부분의 기차역은 CCTV 모니터링을 통해 군중의 움직임을 감시한다. 그러나 이 시스템의 치명적 한계는 이미 혼잡이 발생한 후에야 인식할 수 있다는 점이다. 관제센터에서 “지금 특정 통로가 혼잡하다”는 것을 확인한 시점에는 이미 수백 명이 그 공간에 집중되어 있다. 이 시점에서 할 수 있는 조치는 안내방송이나 역무원 급파 정도에 그친다. 이미 혼잡한 공간에 진입한 승객들은 되돌아가기 어렵고, 특히 환승 시간이 촉박하거나 출근 시간에 쫓기는 이용객들은 혼잡을 감수할 수밖에 없다. 공간 이용

행태 연구들은 이용객들이 최단 거리가 아닌 시각적 개방성, 편의시설 접근성, 혼잡 회피 등을 종합적으로 고려하여 동선을 선택한다는 점을 밝혔으나, 미래의 혼잡 상황을 예측하는 데는 한계가 있다. 결국 사후 모니터링 방식은 “지금 막혔다”는 정보만 제공할 뿐, “20분 후 특정 지점이 혼잡할 것이다”는 예측은 불가능하다.

1.1.2 단순 지표에만 의존

현재 혼잡도 예측 시스템은 주로 인구 밀도와 교통카드 사용량이라는 단순한 지표에 의존한다. 특정 시간대에 개찰구를 통과하는 인원 수를 집계하고, 과거 동일 시간대의 평균 이용객 수를 참고하여 혼잡도를 추정한다. 그러나 실제 혼잡도는 훨씬 복잡한 변수들의 상호작용으로 결정된다. 갑작스러운 폭우, 인근 행사, 열차 지연, 계절별 변화 등 돌발 변수들은 단순 통계나 과거 평균값으로는 반영할 수 없다. 교통카드 사용량만 보면 “지금까지 몇 명이 들어왔는가”는 알 수 있지만, “앞으로 몇 명이 더 들어올 것인가”, “그들이 어느 방향으로 이동할 것인가”는 예측할 수 없다. 또한 현재 시스템은 각 데이터 소스가 독립적으로 운영된다. CCTV, 열차 운행 정보, 기상 정보가 실시간으로 통합 분석되지 않는다. 서울역의 경우 KTX, 지하철

1·4호선, 공항철도가 각기 다른 운영 주체에 의해 관리되어 정보 공유가 원활하지 않다.

1.1.3 복잡한 혼잡 양상 반영 부족

군중 혼잡은 단순한 인원 수의 문제가 아니라 공간적, 시간적으로 복잡하게 얽힌 현상이다. 군중 이동은 개개인의 행동이 상호작용하며 전체적인 패턴을 형성하는 복잡계의 성격을 띤다. 좁은 통로, 계단, 에스컬레이터 출구 등에서 병목 현상이 발생하고, 이것이 주변 공간의 혼잡도에 연쇄적으로 영향을 미친다. 시간적으로도 복잡한 패턴이 존재한다. 출퇴근 시간대 안에서도 5분 단위로 혼잡도가 급변하며, 여러 열차가 비슷한 시간에 도착하면 순간적으로 인파가 물리는 주기적 패턴이 나타난다. 또한 군중 혼잡은 비선형적 특성을 가진다. 한 열차의 5분 지연이 특정 승강장에 수백 명의 군중을 집중시키고, 이것이 환승 통로의 병목을 유발하며, 결과적으로 역 전체의 흐름을 교란시킬 수 있다. 기존 시스템은 이러한 복잡한 혼잡 양상을 제대로 반영하지 못한다. 각 지점의 혼잡도를 독립적으로 측정할 뿐, 지점 간의 상호작용이나 시간에 따른 동적 변화를 종합적으로 분석하지 못한다.

1.2 연구의 목적

이러한 기존 예측 방법의 한계를 극복하기 위해 최근 AI 기술을 활용한 혼잡도 예측 연구가 활발히 진행되고 있다. AI, 특히 머신러닝과 딥러닝 기술은 대규모 데이터를 실시간으로 처리하고, 복잡한 비선형 패턴을 학습하며, 다양한 변수의 상호작용을 종합적으로 분석할 수 있다는 강점을 가진다.

본 연구는 기차역 공간의 혼잡도 예측을 위해 개발된 AI 기반 기술들과 그 실제 적용 사례를 체계적으로 검토하는 데 목적이 있다. 구체적으로 다음의 연구 질문에 답하고자 한다: 첫째, 혼잡도 예측에 적용된 AI 모델들은 어떤 기술적 특징을 가지는가? 둘째, 각 AI 모델의 성능 차이는 무엇인가? 셋째, 해외 기차역에서는 이러한 AI 기술을 어떻게 실제 운영에 적용하고 있는가?

본 연구는 선행연구 검토를 통해 AI 기반 혼잡도 예측 기술의 현황을 파악하고, 실제 적용 사례를 분석함으로써 향후 기차역 공간 설계와 운영에 활용 가능한 기술적 기반을 제공하고자 한다. 특히 건축학 관점에서 공간의 혼잡도 문제를 다루며, 물리적 확장이 제한된 기차역 환경에서 소프트웨어적 접근의 가능성을 탐색한다.

2. 이론고찰

기차역 공간의 혼잡도 예측은 복잡한 시공간적 인과 이동 패턴을 정확하게 파악해야 하는 문제로, 기존의 ARIMA, 칼만 필터(Kalman filters), K-Nearest Neighbors와 같은 단기 예측 모델이 가지는 시공간적 비선형 패턴 포착 한계를 극복하기 위해 머신러닝(ML) 및 딥러닝(DL) 모델을 중심으로 연구가 진행되고 있다 (Kumar & Vanajakshi, 2015; Ojeda et al., 2013; Cai et al., 2017).

2.1. 머신러닝 기반 앙상블 모델: 상황적 특징 및 혼잡 지수 예측

머신러닝 기반 앙상블 부스팅 모델들은 주로 도로 교통 혼잡 예측 분야에서 사용되었으며, 대규모 데이터를 처리하고 시간대, 날씨, 공휴일 등 다양한 상황적 특징(contextual features)을 통합하여 예측 정확도를 높이는 데 강점을 보인다.(Xu et al., 2022; Zhang et al., 2023).

2.1.1. XGBoost, LightGBM, CatBoost의 적용 사례 및 성능 지표




그림1. XGBoost의 아키텍처

앙상블 부스팅 모델 중 XGBoost (eXtreme Gradient Boosting)는 대규모의 고차원 데이터셋을 다루는 데 효과적이며, 규제 기법(regularization techniques)을 적용해 과적합을 방지하고 복잡한 특징 상호작용을 포착한다 (Li et al., 2021; Wang et al., 2022). 특히 이스탄불 교통 데이터를 활용한 Soni & Masih(2025)의 연구에서는, 교통 밀도(density)를 통합한 수정된 교통 혼잡 지수(M_TCI)를 정의하여 XGBoost 모델에 적용했다. 이 연구에서 XGBoost는 다른 앙상블 모델(CatBoost, GBM, LightGBM)보다 우수한 성능을 보였으며, 정확도 90%, MAE 0.50, MSE 0.35, R^2 0.92를 기록해 가장 높은 설명력을 보였다 (Soni & Masih, 2025, p. 156). 또한 시간 관련 특징 중 'week', 'month', 'time period'가 혼잡 지수 변화에 가장 중요한 변수로 분석되었다 (Soni & Masih, 2025, Fig.1). 다만 XGBoost는 계산 복잡성이 높아 대규모 데이터셋에서 처리 속도가 느릴 수 있으며, 성능을 확보하기 위해 광범위한




그림2. LightGBM의 최적화된 아키텍처

특징 엔지니어링이 필요하다는 한계도 보고되었다 (Li et al., 2021; Wang et al., 2021).

반면 LightGBM (Light Gradient Boosting Machine)은 히스토그램 기반 의사결정 트리를 사용해 XGBoost보다 훨씬 빠르고 계산 효율성이 높아 스마트시티 IoT 교통 예측에서 92% 정확도를 달성한 바 있다 (Zhang et al., 2023, p. 152). 그러나 작은 데이터셋에서는 과적합이 발생하는 경향이 있어 희소 데이터(sparse data)에는 적합하지 않다는 한계도 있다.

CatBoost는 도로 유형, 사고 정보 등 범주형 특징(categorical features)을 별도 전처리 없이 다룰 수 있어 고속도로 혼잡 예측에서 91% 정확도를 기록했다 (Chen et al., 2022). 하지만 범주형 처리를 위해 훈련 시 더 많은 메모리를 요구하며 LightGBM 대비 처리 속도가 느린 경향이 있다.

2.1.2. SVR (Support Vector Regressor) 기반 장기 예측




그림4. Support Vector Regression (SVR)

SVR (Support Vector Regressor)은 고차원 특징 공간에서 선형 회귀 함수를 계산하는 감독 학습 알고리즘으로, 비선형 함수인 RBF(Radial Basis Function) 커널을 통해 입력 데이터를 고차원으로 매핑하여 비선형적인 교통 예측 문제를 해결하는 데 사용된다 (Basak et al., 2007; Yasir et al., 2025). 인도의 뉴델리(New Delhi) 교통 데이터를 사용한 Yasir et al.(2025) 연구에서는, SVR을 활용해 요일, 시간, 기상 요인(온도·습도·풍속 등)을 통합한 1주일 장기 예측 모델을 제안했다. 해당 연구는 HERE API를 통해 수집된 교통·기상 데이터를 5분 간격으로 기록하여 학습에 사용했으며, 제안된 모델은 평균 RMSE 1.12의 성능을 달성했다 (Yasir et al., 2025, p.1-2). 연구진은 이러한 장기 예측 모델이 다양한 영향 요인을 통합했음에도 불구하고, 학습 1주 + 테스트 1주의 작은 데이터셋 규모 때문에 RMSE가 기대보다 높게 나타났다고 분석했다. 또한 향후 데이터셋 확대 및 실시간·과거 데이터의 결합을 통해 정확도를 향상시킬 계획임을 제시했다 (Yasir et al., 2025, p.3).

2.2. 딥러닝 기반 군중 흐름 및 밀집도 예측

딥러닝 모델은 교통 및 군중 흐름 데이터의 복잡한 시공간적 종속성을 자동으로 포착하는 데 강점을 가지며, 이는 특히 기차역과 같이 밀집된 환경의 혼잡도 예측에 필수적이다.

2.2.1. GNN 기반 접근 (CrowdNet)




그림5. CrowdNet의 아키텍처

CrowdNet은 Cardia et al.(2022)이 제안한 그래프 컨볼루션 네트워크(Graph Convolutional Network, GCN) 기반의 군중 흐름 예측 모델로, 기존 CNN 기반 모델들이 가진 규칙적 격자(regular tessellation) 입력 의존성을 극복하기 위해 개발되었다. CrowdNet은 도시 공간을 노드(지역)-엣지(이동 흐름) 구조의 그래프로 표현함으로써, 기차역 내부처럼 불규칙적 형태(irregular shapes)의 공간에서도 군중 흐름을 안정적으로 예측할 수 있는 특징을 가진다 (Cardia et al., 2022, p.1-2). 모델은 시간적 종속성(temporal dependency)을 CNN 기반 Time Block으로 학습하고, 공간적 종속성(spatial dependency)을 GCN 기반 Spatial Block으로 학습하는 ST-GCN Block 구조를 사용하며, 이를 통해 근거리·원거리 시공간 패턴을 동시에 포착한다. 이는 기존 STResNet이 가지던 “가까운 지역 중심의 2D grid 구조”라는 제약을 벗어나, 행정구역 기반의 불규칙 구획 등 다양한 공간 단위에서도 예측이 가능하게 한다 (Cardia et al., 2022, p.1-3). CrowdNet의 핵심적인 장점은 단순한 총 유입(inflow)과 총 유출(outflow) 값을 예측하는 것이 아니라, Origin-Destination (OD) 행렬 자체를 예측한다는 점이다. 예측된 OD 행렬을 바탕으로 노드 크기(유입량), 엣지 두께(흐름 규모)를 시각화하여, 정책 입안자가 “어디서 유입되고 어디로 이동하는지”를 직관적으로 파악할 수 있는 네트워크 기반 분석이 가능하다 (Cardia et al., 2022, Figure 6, p.7). 성능 평가에서 CrowdNet은 BikeNYC 데이터셋(1000m 타일, 60분 간격) 기준으로 RMSE 8.53을 기록하여, 기존 모델인 STResNet(9.38)보다 우수한 결과를 보였다. 특히 시간 간격이 커질수록 CrowdNet의 성능 우위는 더욱 두드러졌으며, 이는 장기 패턴을 포착하는 데 있어 그래프 기반 접근 방식의 장점을 보여준다 (Cardia et al., 2022, Table 4, p.6). 또한 불규칙 행정구역(irregular tessellation)을 적용한 실험에서도 CrowdNet은 실제 군중 흐름 패턴을 매우 정확하게 재현해 기존 CNN 기반 모델들이 다룰 수 없던 공간 구조에서도 robust한 성능을 보였다 (Cardia et al., 2022, Figure 4, p.7).

2.2.2. CNN 기반 시공간 네트워크 (STResNet)

STResNet (Spatio-Temporal Residual Network)은 딥러닝 기반 군중 흐름 예측 분야에서 가장 널리 활용되는 대표적인 모델로, 시공간 패턴을 ‘근접성(closeness)-주기성(period)-계절성(trend)’이라는 세 가지 시간 의존 요소로 분해하여 학습하는 방식이 특징이다. 해당 구성은 DeepST로부터 발전된 구조이며, 시간적 패턴을 CNN 기반의 Residual Unit으로 학습해 예측 성능을 강화하였다 (Zhang

et al., 2017; Cardia et al., 2022, p.1). STResNet은 규칙적인 그리드(regular tessellation) 형태의 입력이 필요하다는 명확한 구조적 제약이 존재한다. CrowdNet 논문에서는 STResNet이 “격자 기반 2D convolution에 의존하므로 irregular region representation이 불가능하다”고 명시하고 있으며, 이는 복잡하고 불규칙한 실내 공간(예: 다층·다중 연결 구조의 기차역)에서는 적용이 어렵다는 한계를 의미한다(Cardia et al., 2022, p.2-3). 그럼에도 STResNet은 단순 ARIMA·VAR 등 통계 모델 대비 매우 우수한 RMSE 성능을 지속적으로 보여주었고, CrowdNet 논문 실험에서도 동일한 경향을 확인할 수 있다. BikeNYC 데이터셋 실험 결과에서 STResNet은 RMSE 9.38을 기록해 CNN 기반 모델의 강점을 입증했지만, CrowdNet의 RMSE 8.53 보다는 낮은 성능을 보였다(Cardia et al., 2022, Table 4, p.6). 결과적으로 STResNet은 시공간 패턴 모델링 능력은 뛰어나지만, 격자 기반 입력 데이터 제한 때문에 불규칙한 구조를 가진 기차역 내부(계단·통로·게이트 간 연결 형상 등)에는 직접 적용하기 어렵다는 구조적 제약을 갖는다. 이는 CrowdNet이 등장하게 된 주요 배경으로도 제시된다(Cardia et al., 2022, p.1-2).

2.2.3. 딥러닝 기반 비전 모델: 밀집도 추정 및 분류 (Vision Transformer / Faster CNN / ABiGRU)

Faster CNN-ViT Fusion Model




그림6. Faster R-CNN과 Vision Transformer

실시간 비디오 감시 시스템을 활용한 군중 밀집도(Crowd Density) 추정 및 분류는 기차역과 같은 대규모 환승 공간에서 안전 관리의 핵심 요소이다. 최근 연구는 고밀도·가려짐·스케일 변화가 존재하는 복잡한 환경에서도 높은 정확도와 강건성을 확보하기 위해 CNN 기반 백본과 Transformer 기반 전역 컨텍스트 학습을 결합한 하이브리드 모델을 집중적으로 개발하고 있다(Khan et al., 2023, p.1-2).

Faster CNN-ViT 융합 모델은 Faster R-CNN의 지역 기반 탐지 능력과 Vision Transformer(ViT)의 전역적 패턴 인식 능력을 결합하여 밀집 환경에서의 군중 계수(crowd

counting)를 향상시키기 위해 설계되었다. Faster R-CNN의 RPN(Region Proposal Network)이 후보 객체 영역을 제안하면, ViT는 해당 영역을 패치 단위로 분할해 내적 주의(self-attention)를 통해 long-range dependency와 global context를 학습한다. 두 모델의 특징(feature)은 concatenation 등 벡터 융합 기법을 통해 결합되어 최종 회귀 또는 분류 네트워크에 입력된다(Khan et al., 2023, p.3-4). Faster CNN이 지역적 특징을 포착하고 ViT가 전역적 종속성을 학습한 뒤 이를 feature fusion으로 결합하는 구조는 기존 순수 CNN 기반 모델(CSRNet, MCNN)보다 더 높은 정확도를 제공할 뿐 아니라, 순수 Transformer(ViT) 단독 모델이 겪는 불안정성과 고밀도 환경에서의 localization 실패 문제를 효과적으로 보완하는 것으로 보고되었다(Khan et al., 2023). 실험 결과, Faster CNN-ViT 융합 모델은 CrowdNet 데이터셋에서 MAE 45.6, MSE 68.9, AP 82.5%의 성능을 기록하며 기존 CNN 계열 모델 대비 정확도를 크게 향상시켰고, ViT 단독 모델보다 안정적인 특성 학습 능력을 보여주었다. 이는 고밀도·가려짐·스케일 변화가 심한 환경에서도 적용 가능성이 높다는 점을 시사한다(Khan et al., 2023).

또한 ViT 계열과 CNN 계열 외에도, 시계열 기반 군중 변동을 예측하기 위한 Attention-Based BiGRU(ABiGRU) 모델이 소개되며, 이는 시간적 패턴 변화가 중요한 감시 시스템(예: 승강장 혼잡 변화 예측)에 효과적이라고 제시한다(Khan et al., 2023, p.3). 또한 OOADL-CDDC (Osprey Optimization Algorithm with Deep Learning-Assisted Crowd Density Detection and Classification) 기술은 스마트 비디오 감시 환경을 위해 제안된 방식으로, ABiGRU (Attention Bidirectional Gated Recurrent Unit) 모델을 사용하여 군중 밀집도를 분류한다. ABiGRU는 순방향 및 역방향 GRU로 구성된 양방향 구조를 통해 순차 데이터의 시간적 종속성을 모두 포착하며, 여기에 어텐션 메커니즘을 결합하여 각 시점(time step)에서 가장 관련성이 높은 특징에 집중하도록 설계되었다(Khan et al., 2023, p.2-3). 이 기술은 SE-DenseNet을 사용해 이미지 특징을 추출하고, Osprey Optimization Algorithm(OOA)을 활용하여 하이퍼파라미터를 최적화한다(Khan et al., 2023, p.3-4). 실험 결과, OOADL-CDDC 모델은 네 가지 밀집도 클래스(‘Dense Crowd’, ‘Medium Dense Crowd’, ‘Sparse Crowd’, ‘No Crowd’)를 분류하는 과제에서 평균 정확도 98.30%를 달성하여 매우 높은 성능을 보였다(Khan et al., 2023, p.4).

2.3 모델별 기술 특성 비교

교통 및 군중 예측 모델이 실시간 의사 결정 및 안전 관리에 사용하려면 투명성과 신뢰성이 필수적이다. SHAP (SHapley Additive Explanations) 기법은 딥러닝 모델의 “블랙 박스” 특성을 해소하기 위해 사용될 수 있다. SHAP은 각 특징(또는 이미지의 픽셀)이 최종 예측 결과에 얼마나 기여했는지 Shapley 값을 할당하여 정량적으로 설명함으로써, 예측의 해석 가능성을 높인다. 이러한 XAI의 통합은 특히 승객 안전에 직결되는 기차역 환경에서 AI 기반 예

모델 계열	주요 모델	주요 예측 대상	기술적 특징 및 데이터 활용	강점	성능 (주요 지표)
양상블 ML	XGBoost/ LightGBM	도로 교통 혼잡 지수 (M_TCI)	시간적/상황적(날씨, 휴일) 특징 통합. 밀도(Density)와 속도(Speed)를 결합한 지수 사용.	높은 예측 정확도(Accuracy 90~92%). 상황 변화 예측에 유리.	XGBoost R ² 0.92, LightGBM Accuracy 92%
DL / GNN	CrowdNet	군중 흐름 (유입/유출, OD 행렬)	GCN을 이용한 시공간 그래프 모델링. CNN으로 시간 종속성 처리.	불규칙한 기차역 공간 구조에 최적화됨. OD (출발지-도착지) 흐름 방향 예측 가능.	BikeNYC RMSE 8.53 (STResNet 대비 우수)
DL / CNN/RNN	ABiGRU + SE-DenseNet	군중 밀집도 분류	SE-DenseNet으로 특징 추출, ABiGRU로 양방향 시간 종속성 및 어텐션 기반 분류. OOA로 최적화.	실시간 비디오 감시 기반의 높은 정확도의 밀집도 클래스 분류 (98.30%).	Accuracy 98.30%
DL / Vision Hybrid	Faster CNN + ViT	군중 밀집도 추정/계수	CNN(로컬 특징)과 ViT(전역 컨텍스트)의 특징 융합.	고밀도, 가려짐이 심한 환경에서 정량적 계수 추정 에 탁월.	MAE 45.6, MSE 68.9, AP 82.5%

표1. 모델별 기술 특성 비교

측 시스템의 신뢰를 구축하는 데 중요하다. 선행 연구 검토 결과, 기차역 혼잡도 예측을 위해서는 공간의 불규칙성을 반영하고 승객 흐름의 기원과 목적지(OD)를 파악할 수 있는 CrowdNet과 같은 GNN 기반 모델이 가장 유연한 프레임워크를 제공한다. 동시에, 실시간 카메라 영상을 활용하여 정밀한 인원 수를 파악하고 안전 입계치를 관리하기 위해서는 Faster CNN + ViT와 같은 비전 기술 융합 모델이 높은 성능을 보여준다. 따라서 기차역의 물리적 한계를 소프트웨어적으로 극복하기 위해, 불규칙 공간 기반의 OD 흐름 예측과 고정밀 비전 기반 밀집도 추정 기술을 결합하는 다중 모델 접근 방식이 효과적일 것으로 사료된다.

3. 해외 기차역 실제 적용 사례

최근 도시 철도 및 대규모 교통시설에서 인공지능(AI)을 활용한 혼잡 예측 기술은 운영 효율성 향상과 안전 확보의 수단으로 주목받고 있다(e.g., Hörcher et al., 2017; Jenelius et al., 2020; Basso et al., 2023). 스마트카드 데이터, CCTV 영상, IoT 센서, 소셜미디어 등의 데이터를 통합하여 대규모 군중의 이동 패턴을 정량적으로 분석하려는

시도가 지속적으로 확대되고 있으며(Tian et al., 2020; Tuncel et al., 2024; Hu et al., 2024), 이러한 기술은 단순한 통행량 예측을 넘어 ‘공간적 의사결정 지원 도구’로 발전하고 있다. 대규모 교통 거점에서의 혼잡 관리는 단순 수요예측을 넘어, 공간 조직(승강장-계단-통로-출입구)의 상호작용을 실시간으로 해석하고 운영 규칙(동선 분리, 일시 통제, 안내 전략)로 환원하는 프로세스가 핵심이다. 이하 두 사례는 운영 단계(Operational)와 계획 단계(Planning)의 서로 다른 초점을 통해, 데이터-공간-운영이 통합되는 방식의 스펙트럼을 보여준다.

3.1 홍콩 - MTR 카이탁 스포츠파크역 지능형 군중 분산 시스템

3.1.1 도입 배경

홍콩 MTR(Mass Transit Railway)은 2025년 3월 개장 예정인 카이탁 스포츠파크의 운영 준비 과정에서, 약 65,000명 규모의 대형 이벤트 관객이 단시간 내 특정 시간대에 집중적으로 이동하는 문제에 직면하였다. 기존의 군중 관리 방식은 경험적 판단과 현장 인력에 의존했으며, 실시간 데이터 기반의 대응 체계가 부족했다. 이에 따라 MTR은 “예측 기반 운영(Predictive Operation)” 개념을 도입하

여, AI와 빅데이터를 결합한 실시간 군중 흐름 예측 시스템을 개발했다(PR-25-039-E, 2025).

3.1.2 시스템 구성 및 기술적 구조

시스템은 크게 두 개의 주요 모듈로 구성된다:

- (1) Ridership Prediction Model(승객 수요 예측 모델) 과
- (2) Intelligent Crowd Diversion System(지능형 군중 분산 시스템).

① Ridership Prediction Model 은 과거 교통카드 이용 기록, 열차 운행 데이터, 날씨, 경기 일정 등 외생 변수를 통합 분석해 특정 이벤트 종료 시 발생할 승객 흐름을 예측한다. 이 모델은 다중 회귀와 머신러닝 예측 알고리즘을 결합하여 시간대별 승객 분포를 시뮬레이션하며, 행사 종료 30분 전부터 예상 혼잡도를 시각화한다.



그림7. 홍콩 전역 철도 네트워크에서의 실시간 혼잡 흐름 예측

② 지능형 군중 분산 시스템 은 CCTV·IoT 센서·Wi-Fi 탐지 데이터를 실시간 수집하여 역 내부의 인구 밀도를 추정하고, 혼잡 구간이 발생하기 전 단계에서 자동으로 대응 시나리오를 제시한다. 예를 들어, 특정 출구에 인파가 몰릴 경우 다른 출구를 안내하거나, 임시 통제선 및 개찰구 개방을 자동 제안한다. 또한 MTR은 실제 행사 전에 Online Drill(온라인 모의훈련) 기능을 운영하여, 가상환경에서 여러 시나리오를 반복 학습시킴으로써 운영 요원의 대응 숙련도를 높였다. 이러한 구조는 단순한 기술적 자동화 시스템을 넘어, 사람-AI 협업형 운영 체계(Human-AI Collaborative Control) 로 진화한 사례로 평가



그림8. 도시 전체 범위의 관광객·관람객 분산 시뮬레이션

된다.

3.1.3 성과 및 시사점

이 시스템은 카이탁 스포츠파크 개장 행사에서 처음 운영되었으며, 약 65,000명의 관객이 이용했음에도 불구하고 평균 대기시간이 약 15분 단축, 예측 오차율 7% 이내, 열차 운행 간격 20% 최적화 등 정량적 성과를 달성했다. 또한, 해당 프로젝트는 2025년 독일 함부르크에서 열린 UITP(International Association of Public Transport) 서밋에서 “Operational Excellence” 부문 최우수상을 수상하였다. 이 사례는 단순히 혼잡 예측의 정밀도를 높이는 것에 그치지 않고, AI를 활용한 운영 의사결정 체계의 혁신적 모델로 인정받았다. 결과적으로 MTR 카이탁 사례는 사전 예측(Planning)과 실시간 대응(Operation)의 하이브리드형 시스템으로서, 건축적 공간 분석과 데이터 기반 운영을 통합한 모범적 사례로 평가된다.




그림9. 카이탁역 내부의 출입구별 실시간 유입량 분석(ICDS)

3.2 일본 - 도쿄돔 주변 실시간 군중 흐름 예측 시스템

3.2.1 도입 배경

일본 오사카대학교 사이버미디어센터 연구팀은 대규모 행사 후 발생하는 보행자 혼잡을 예측하기 위해 “CMPaaS(Crowd Management Platform as a Service)” 를 개발하였다(19_248, 2024). 도쿄돔은 약 55,000명을 수용하는 복합 문화시설로, 경기나 콘서트 종료 직후 약 10분 내에 인근 JR 스이도바시역과 코라쿠엔역으로 수만 명이 몰리는 구조적 특성을 가진다. 기존에는 CCTV 관제와 현장 요원 배치로 대응했지만, 실시간 예측이나 혼잡 파동(stop-and-go wave) 현상을 사전에 감지하는 것은 어려웠다.

3.2.2 시스템 구성 및 기술

도쿄돔 사례는 에이전트 기반 군중 시뮬레이션(agent-based simulation) 을 핵심으로 한다. Pathfinder 엔진을 사용해 개인 단위 보행자(Agent)를 생성하고, 실제 도면(CAD) 데이터를 바탕으로 Navigation Mesh를 구축하였다. 이를 통해 밀도-속도 관계, 개인 거리 유지 파라미터(0.33m), 보행 속도 $1.36 \pm 0.21 \text{ m/s}$, 밀도 2.2 명/m^2 이상 시 속도 85% 감소 등의 현상이 정량적으로 반영되었다. Python 제어 스크립트는 CMPaaS의 API로부터 1분 단위

감지 데이터를 받아, 향후 10분 간의 혼잡 변화를 시물레이션한다. Nash-Sutcliffe 효율계수(NSE) 0.797, 이동평균 적용 시 0.882를 기록하며, 실측 대비 높은 예측 정확도를 달성했다. 3,000명 규모의 시물레이션이 약 95초 만에 완료되어 실시간 처리(near real-time) 가능성이 입증되었다.




그림10. 도쿄돔 주변 보행 네트워크 및 주요 동선 구성(Line01-Line12)

특히 이 시스템은 정지-이동 파동(stop-and-go wave) 현상을 실측 데이터와 동일하게 재현하였는데, 이는 단순한 통계 기반 모델로는 구현하기 어려운 비선형 동역학을 포착




그림11. 도쿄돔 보행 시물레이션 LOS 변화(오차 시나리오 +50%, +100%)

3.2.3 성과 및 시사점

도쿄돔 플랫폼은 복잡한 군중 흐름을 LOS(Level of Service) 기준 히트맵으로 시각화함으로써, 운영자가 혼잡 구간을 직관적으로 인식하고 사전에 대비할 수 있게 하였다. 또한 오차 시나리오(-20%, +20%, +50%, +100%) 분석을 수행해 입력 데이터의 불확실성이 결과에 미치는 영향을 평가했으며, 다중 시나리오 병렬 처리 방식을 통해 불확실성 기반 의사결정(Uncertainty-aware Decision Making) 프레임워크를 제시했다. 이 연구는 실시간 군중 예측의 기술적 가능성을 입증하는 동시에, AI를 공간 시물레이션 도구로 확장한 점에서 의미가 크다. 즉, 도쿄돔 사례는 “운영 대응형” 이라기보다 “계획 설계형” 시스템으로, 건축 계획 단계에서 공간 활용 효율성을 미리 검증할 수 있는 가능성을 제시했다.

3.3 사례 비교 분석

두 사례는 AI를 활용한 군중 예측의 서로 다른 방향성과 보완성을 보여준다. 홍콩 MTR 카이탁은 실시간 데이터 통합형 운영 시스템으로, 실제 교통 운영에 적용되어 즉각적 피드백을 제공한다. 반면, 도쿄돔 플랫폼은 에이전트 기반 시물레이션형 계획 도구로, 설계 단계에서의 혼잡 예측과 공간 활용 시나리오 검증에 초점을 둔다.

이 둘을 비교하면 다음과 같다.

	홍콩 MTR 카이탁	일본 도쿄돔
목적	실시간 승객 흐름 예측 및 분산	계획 단계 시물레이션 및 예측
데이터	교통카드 + 센서 + CCTV + 외생 변수	CMPaaS 감지선 데이터
모델 구조	예측 모델 + 실시간 제어 AI	에이전트 기반 시물레이션
예측 단위	분 단위 실시간	10분 후 단위
정확도	오차율 7% 이내	NSE 0.797~0.882
처리 속도	상시 실시간	95초(3,000 agent)
특징	운영형(Operational)	계획형(Planning)
시사점	사전 예측 + 실시간 제어의 통합	공간 구조 기반 비선형 예측

표2. 홍콩, 도쿄 사례 비교

이러한 비교를 통해 확인할 수 있듯이, AI 기반 예측 시스템은 단순히 ‘정확한 수요 예측’에 머무르지 않고, 공간의 구조적 이해와 운영 전략 간의 연계로 발전하고 있다. 즉, AI는 건축적 공간의 효율성을 판단하는 ‘분석 도구’ 이자, 실제 운영의 실시간 대응을 가능하게 하는 ‘통합적 제어 시스템’ 으로 기능할 수 있다.

결과적으로, 기차역 공간에서의 AI 활용은

- 1) 운영형(Operational) : 실시간 피드백을 통한 안전 확보와 서비스 효율화,
- 2) 계획형(Planning) : 설계 단계에서의 공간 동선 및 혼잡 시뮬레이션 예측의 두 축이 병행될 때 가장 높은 효과를 발휘한다.

4. 결론

본 연구는 인구 밀집과 이동이 집중되는 현대 도시의 기차역 공간에서, AI 기반 예측 기술이 군중 혼잡을 사전에 인지하고 공간 운영의 효율성을 높일 수 있는 가능성을 제시하였다. 기존의 관제 중심 방식은 사후 대응에 머물렀으나, AI를 활용한 분석은 시간대별·공간별 흐름의 패턴을 해석함으로써 이용자 경험과 안전성을 동시에 향상시킬 수 있는 새로운 접근을 보여준다. 특히 해외 주요 역사의 사례를 통해, AI 기술이 단순한 데이터 관리 수단이 아니라 공간 구조와 이용자 행동을 연결하는 관찰 도구로 작동할 수 있음을 확인하였다. 이는 복합적 동선 구조를 가진 대형 역사의 설계와 운영에서, 예측 데이터를 건축적 의사결정의 초기 단계에 통합하는 방향으로 발전될 수 있음을 시사한다.

본 연구는 기술적 실험을 수행하기보다, AI 기반 예측 연구의 흐름을 건축 공간의 맥락에서 재해석하고 그 적용 가능성을 탐색했다는 점에 의의가 있다. 향후 연구에서는 스마트카드 기반 교통데이터 분석(Hörcher et al., 2017; Tian et al., 2020), 실시간 군중 예측 및 시각화 플랫폼 구축(Tuncel et al., 2024; Ho & Ho, 2018), 그리고 그래프 신경망을 활용한 보행자 흐름 예측(Social-STGCNN, 2020 등)과 같은 주요 선행연구들을 참고하여, 실제 역사 데이터를 기반으로 한 시뮬레이션과 데이터 기반 설계 프레임워크를 심화할 필요가 있다.

참고문헌

1. Yasir, R. M., Asad, M., Nower, N., & Shoyaib, M. (2025). Traffic Congestion Prediction Using Machine Learning Techniques. arXiv:2206.10983v5.
2. Soni, D., & Masih, S. (2025). Improved Road Traffic Congestion Prediction Using Machine Learning through Modified Index. In Proceedings of the International Conference on Recent Advancement and Modernization in Sustainable Intelligent Technologies & Applications (RAMSITA-2025), Advances in Intelligent Systems Research, 192. https://doi.org/10.2991/978-94-6463-716-8_13
3. Cardia, S., Simonetto, A., & Chou, P. (2022). CrowdNet: Graph-based Spatio-Temporal Deep Learning for Crowd Flow Prediction in Irregular Regions. arXiv:2203.07372v1.
4. Hu, Z., Li, T., & Gao, Y. (2024). Integrating Explainable Artificial Intelligence with Transformer Networks for Real-Time Highway Congestion Prediction. Transportation Research Part C: Emerging Technologies, 158, 104382.
5. Tuncel, A., Mo, X., & Shin, H. (2024). Enhancing Urban Traffic Flow Forecasting with Spatio-Temporal Graph Convolutional Networks (ST-GCN). Pattern Recognition, 154, 110648.
6. Hörcher, D., Graham, D. J., & Anderson, R. J. (2017). Crowding and Public Transport Demand: The Role of Congestion Externalities in Large Cities. Transportation Research Part A: Policy and Practice, 103, 306-318.
7. Kim, S. M., Park, H. J., & Lee, J. S. (2023). A Study on Space Use Behavior of Passengers in Congested Subway Stations Using Space Syntax and Agent Analysis. Journal of the Architectural Institute of Korea Planning & Design, 39(5), 81-92.
8. Park, M. J., & Kwon, Y. J. (2023). Survey on Perceived Congestion and Satisfaction in Urban Railway Stations. Journal of the Architectural Institute of Korea, 39(3), 115-126.
9. Kim, D. H., & Jang, S. Y. (2023). A Study on Crowd Congestion Patterns in Large-Scale Demonstrations. Journal of Safety and Disaster Management, 22(4), 55-67.
11. Han, J. H., & Choi, E. S. (2023). Multi-Crowd Movement Detection and Risk Assessment System for Fire Safety Based on CCTV Video Analysis. Journal of the Korea Institute of Fire Science & Engineering, 37(6), 89-100.
12. Bae, Y. J., & Choi, J. H. (2022). Integrating Explainable Artificial Intelligence with Smart Transportation Infrastructure for Congestion Prediction. Sustainability, 14(12), 7594. doi:10.3390/su14127594.
13. Tuncel, E., & Basso, F. (2023). AI-Based Congestion Prediction Models Using Smartcard Data in Metro Systems. Transportation Research Part C: Emerging Technologies, 157, 104013. doi:10.1016/j.trc.2023.104013.
14. Kushwaha, H., & Gupta, S. K. (2024). Efficient Crowd Density Estimation: Fusion of Faster CNN and Vision Transformer. Research Square, DOI: 10.21203/rs.3.rs-4630456/v1